

Regressão Linear com uma Variável

A regressão linear simples é um dos modelos estatísticos mais fundamentais e poderosos para compreender relacionamentos entre variáveis. Este modelo matemático nos permite prever uma variável dependente (Y) a partir de uma variável independente (X), estabelecendo uma relação linear entre elas.

O conceito central é ajustar uma reta aos dados de treinamento disponíveis, criando um modelo capaz de fazer previsões precisas para novas observações. É a porta de entrada para o mundo do machine learning supervisionado e uma ferramenta essencial para análise de dados.

Entendendo Variáveis e Relacionamentos

Variável Independente (X)

Representa a "**causa**" no relacionamento. É a variável que usamos para fazer previsões, também conhecida como variável preditora ou explicativa.

Características:

- Controlada ou observada
- Não é influenciada por outras variáveis do modelo
- Base para as previsões

Variável Dependente (Y)

Representa o "**efeito**" que queremos prever. É a variável resposta que depende dos valores da variável independente.

Características:

- É o que queremos prever
- Varia em função de X
- Também chamada de variável resposta

 **Exemplo prático:** Experiência profissional (anos) → Salário anual (R\$). A experiência é nossa variável independente e o salário é o que queremos prever.

A Matemática por Trás da Regressão Linear Simples

A regressão linear simples utiliza **uma única variável independente** para fazer previsões. O modelo é representado geometricamente por uma reta no plano cartesiano, expressa pela equação fundamental:

$$h(x) = \theta_0 + \theta_1 x$$

θ_0 (Intercepto)


Valor de Y quando X = 0. Representa o ponto onde a reta cruza o eixo Y. É o valor base da nossa previsão.

θ_1 (Inclinação)

Taxa de variação de Y em relação a X. Indica quanto Y aumenta (ou diminui) para cada unidade adicional de X.

Esta equação linear nos permite calcular qualquer previsão simplesmente substituindo o valor de X desejado na fórmula.

Modelo da reta: salário em função da experiência



$$h(x_1) = \overbrace{\hat{y}}^{\text{variável dependente}} = \overbrace{b_0}^{\text{intercepto em y}} + \underbrace{b_1}_{\text{inclinação da reta}} * \overbrace{x}^{\text{variável independente}}$$

modelos linear (hipótese)

$$\text{salário} = b_0 + b_1 * \text{experiência}$$

Aplicando a Equação na Prática

Vamos trabalhar com um exemplo concreto para entender como a equação funciona:

01

Definindo os Parâmetros

$\theta_0 = \text{R\$ } 20.000$ (salário base) e $\theta_1 = \text{R\$ } 5.000$
(aumento por ano de experiência)

02

Aplicando a Fórmula

Para 3 anos de experiência: $h(3) = 20.000 + 5.000 \times 3$

03

Resultado Final

$h(3) = \text{R\$ } 35.000$ de salário previsto


❓ **Mini-Exercício:** Se $\theta_0 = \text{R\$ } 15.000$ e $\theta_1 = \text{R\$ } 6.000$, qual seria o salário previsto para alguém com 4 anos de experiência?
Resposta: $\text{R\$ } 39.000$ ($15.000 + 6.000 \times 4$)

O Desafio: Escolhendo a Melhor Reta

Quando trabalhamos com dados reais, existem infinitas retas possíveis que podem passar pelos nossos pontos de dados. O grande desafio é determinar qual delas representa melhor o relacionamento entre as variáveis.

O modelo ideal deve **minimizar os erros** entre:

- **Valor real observado:** O que realmente aconteceu nos dados históricos
- **Valor previsto pelo modelo:** O que nossa reta prediz para aquele ponto



❓ **Pergunta para reflexão:** Observando um gráfico com várias retas possíveis, como você determinaria visualmente qual representa melhor os dados?

Função de Custo: Medindo a Qualidade do Modelo

Para avaliar matematicamente quão boa é nossa reta, utilizamos a **função de custo**. A mais comum é o Mean Squared Error (MSE):

$$J(\theta_0, \theta_1) = \frac{1}{m} \sum_{i=1}^m (h(x_i) - y_i)^2$$

1

Calcula o Erro

Para cada ponto, subtrai o valor real do previsto

2

Eleva ao Quadrado

Evita que erros positivos e negativos se cancelem


3

Tira a Média

Obtém o erro médio quadrático do modelo

O objetivo é encontrar os valores de θ_0 e θ_1 que **minimizam** esta função de custo.

Erro do Modelo Linear



Calculando o Erro na Prática

Vamos ver como calcular o MSE com dados reais de um modelo que relaciona experiência e salário:

Experiência	Salário Real	Salário Previsto	Erro ²
3 anos	R\$ 40k	R\$ 35k	$(40-35)^2 = 25$
5 anos	R\$ 50k	R\$ 47k	$(50-47)^2 = 9$

17


MSE Final

Média dos erros quadráticos: $(25 + 9) \div 2 = 17$

Quanto **menor o valor do MSE**, melhor nosso modelo está performando. Um MSE de zero indicaria previsões perfeitas.

Gradiente Descendente: O Motor da Otimização

O gradiente descendente é o **algoritmo de otimização** que encontra automaticamente os melhores valores para θ_0 e θ_1 . Sua missão é minimizar nossa função de custo de forma sistemática e eficiente.



O algoritmo funciona iterativamente, refinando os parâmetros a cada passo até alcançar a configuração ótima.

A Metáfora da Montanha

Para entender intuitivamente como o gradiente descendente funciona, imagine que você está **descendo uma montanha no escuro**:

1

Situação Inicial

Você está perdido no topo da montanha e quer chegar ao vale (mínimo da função)

2

Estratégia Inteligente

A cada passo, você sente a inclinação do terreno com os pés

3


Decisão do Passo

Você sempre caminha na direção mais íngreme para baixo

4

Tamanho do Passo

O learning rate determina se você dá passos grandes ou pequenos



Mini-Exercício para Reflexão: O que você acha que aconteceria se você desse passos muito grandes ao descer a montanha no escuro?

Dica: Pense nos riscos de passar direto pelo vale!

O Algoritmo do Gradiente Descendente

Agora vamos formalizar o algoritmo completo que encontra os parâmetros ótimos para nossa regressão linear:

01

Inicialização

Defina valores iniciais para θ_0 e θ_1 (geralmente zeros ou valores aleatórios pequenos)

02

Iteração Principal

Repita até que o algoritmo convirja (quando as mudanças ficam muito pequenas)

A **regra de atualização simultânea** para ambos os parâmetros é:

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

Onde α (alpha) é o **learning rate** que controla o tamanho de cada passo na otimização.

ⓘ Importante: Os dois parâmetros devem ser atualizados simultaneamente em cada iteração, usando os valores antigos para calcular ambas as derivadas.

Learning Rate: Encontrando o Equilíbrio Perfeito

O **learning rate (α)** é um hiperparâmetro crítico que determina a velocidade de convergência do algoritmo. Escolher o valor certo é uma arte que combina teoria e experimentação prática.

α Muito Pequeno

Vantagem: Convergência garantida e estável

Desvantagem: Processo extremamente lento, pode levar milhares de iterações

α Muito Grande

Vantagem: Convergência rápida quando funciona

Desvantagem: Risco de "pular" o mínimo e divergir completamente

Na prática, valores típicos variam entre 0.001 e 0.3, sendo necessário experimentar para encontrar o ideal para cada problema específico.

Mínimos Globais vs. Locais

Um aspecto crucial da otimização é distinguir entre diferentes tipos de mínimos que uma função pode ter:

Mínimo Local

Ponto onde a função tem o menor valor apenas em uma **vizinhança** limitada. É como estar no fundo de uma pequena depressão, mas não necessariamente no ponto mais baixo de toda a paisagem.

Problema: O algoritmo pode ficar "preso" nestes pontos subótimos.

Mínimo Global

O ponto onde a função tem o **menor valor absoluto** em todo seu domínio. É o verdadeiro objetivo que queremos alcançar.

Vantagem: Representa a solução ótima do problema.

- ✓ **Boa notícia para regressão linear:** A função de custo MSE é matematicamente convexa, garantindo que existe apenas um mínimo global. Isso significa que o gradiente descendente sempre encontrará a solução ótima!

Síntese dos Conceitos Fundamentais

Chegamos ao final de nossa jornada pela regressão linear simples. Vamos consolidar os conceitos principais que formam a base deste poderoso método de machine learning:



Modelagem Linear

A regressão linear ajusta uma reta aos dados históricos, estabelecendo uma relação matemática precisa entre variável independente e dependente através da equação $h(x) = \theta_0 + \theta_1 x$.



Função de Custo

O MSE mede objetivamente a qualidade do nosso modelo, calculando o erro quadrático médio entre previsões e valores reais. Minimizar esta função é nosso objetivo principal.



Otimização Automática

O gradiente descendente encontra automaticamente os parâmetros ótimos, iterando na direção que reduz o erro até alcançar a configuração que melhor representa os dados.



Mini-Exercício Final - Reflexão Conceitual:

Explique com suas próprias palavras:

- Qual o papel fundamental da função de custo no processo de aprendizagem?
- Como o gradiente descendente utiliza essa informação para melhorar continuamente o modelo?