


Modelos de Regressão II — Polynomial Features e Regularização

1. Introdução

Nas aulas anteriores estudamos a regressão linear simples e múltipla. Agora vamos ampliar esse conhecimento explorando dois temas fundamentais: as Polynomial Features e os modelos com regularização (Ridge, Lasso, Elastic Net). O objetivo é entender como aumentar o poder preditivo do modelo sem cair no problema do **overfitting**.

2. Polynomial Features

Apesar do nome, a regressão linear pode ser estendida para capturar relações não lineares. Isso é possível criando novas variáveis que representam potências ou combinações das variáveis originais. Por exemplo, ao invés de modelar apenas $\text{Preço} \sim \text{MedInc}$, podemos incluir também $(\text{MedInc})^2$, permitindo que o modelo se ajuste a uma curva parabólica.



O gráfico mostra a relação entre MedInc (renda mediana) e o valor mediano das casas (target), com diferentes ajustes polinomiais:

- **Polinomial grau 1 (reta azul):** modelo linear simples. Não consegue capturar a curvatura presente nos dados e, portanto, sofre de **underfitting** (subajuste).
- **Polinomial grau 2 (curva laranja):** modelo parabólico. Acompanha melhor a tendência dos dados, oferecendo um bom equilíbrio entre simplicidade e capacidade de ajuste.

- **Polinomial grau 10 (curva verde):** modelo extremamente flexível. A curva tenta seguir cada variação, inclusive ruídos aleatórios, o que pode caracterizar **overfitting**.

✅ **Conclusão:** aumentar o grau do polinômio aumenta a flexibilidade do modelo.

⚠️ No entanto, graus muito altos podem gerar **overfitting**, quando o modelo aprende detalhes específicos do conjunto de treino e perde a capacidade de generalizar para novos dados.

3. Regularização

Com muitas variáveis, especialmente polinomiais, o modelo pode se **ajustar demais** aos dados de treino. Isso reduz sua capacidade de generalização. Para lidar com esse problema, usamos técnicas de regularização, que **penalizam coeficientes muito grandes**.

3.1 O que são coeficientes grande?

Na regressão, cada variável tem um **coeficiente** (β). Esse número indica **quanto o target muda** quando a variável aumenta em 1 unidade (mantendo as outras fixas).

Exemplo:

$$y = 2 \cdot MedInc + 0.01 \cdot AveRooms$$

- Aqui, o coeficiente de MedInc é **2** → grande impacto no preço.
- O coeficiente de AveRooms é **0.01** → impacto pequeno.

Por que penalizar coeficientes grandes?

- **Coeficientes muito grandes** indicam que o modelo está se apoiando **demais** em certas variáveis para ajustar os dados de treino.
- Isso geralmente acontece quando há **overfitting** ou **multicolinearidade** (variáveis correlacionadas).
- Modelos assim podem prever muito bem no treino, mas falham no teste, porque ficaram **sensíveis a variações mínimas**.

Como funciona a penalização?

Na regularização, adicionamos um **custo extra** no treinamento:

- **Ridge (L2):** penaliza o **quadrado dos coeficientes** → força todos a ficarem menores.
- **Lasso (L1):** penaliza o **valor absoluto** dos coeficientes → alguns vão para zero (seleção de variáveis).
- **Elastic Net:** mistura os dois.

Isso **não proíbe** coeficientes grandes, mas “cobra um preço” por eles. O modelo só vai manter coeficientes grandes se eles realmente forem muito necessários para reduzir o erro.

Exemplo sem regularização

Suponha que a regressão encontre:

$$y = 50 \cdot MedInc + 20 \cdot AveRooms + 0.1 \cdot Population$$

- MedInc tem coeficiente **50** → impacto enorme.
- AveRooms tem coeficiente **20** → também muito grande.
- Population quase não influencia (**0.1**).

Esse modelo pode ter **ótimo ajuste no treino**, mas coeficientes tão altos deixam o modelo **instável**: pequenas variações em MedInc ou AveRooms geram mudanças enormes em y.

3.2 Ridge Regression (L2)

A Ridge adiciona uma penalização proporcional ao quadrado dos coeficientes. Isso força os coeficientes a ficarem menores, mas dificilmente zera algum deles. É especialmente útil em modelos com polinômios.

Exemplo com Ridge (L2)

Agora aplicamos penalização. O modelo “paga um preço” por ter coeficientes muito grandes. Ele pode ajustar para algo assim:

$$y = 8 \cdot MedInc + 3 \cdot AveRooms + 0.05 \cdot Population$$

- Todos os coeficientes ficaram **menores**
- O modelo ainda explica a relação, mas de forma **mais estável**.

3.3 Lasso Regression (L1)

A Lasso adiciona uma penalização proporcional ao valor absoluto dos coeficientes. Ela tem a capacidade de zerar coeficientes, funcionando como um método de seleção automática de variáveis. É útil quando suspeitamos que muitas variáveis não são realmente relevantes.

Exemplo com Lasso (L1)

Aqui a penalização é ainda mais forte em alguns casos:

$$y = 7 \cdot MedInc + 0 \cdot AveRooms + 0.04 \cdot Population$$

- AveRooms foi **zerado** → o modelo “decidiu” que ela não ajuda tanto.
- O Lasso faz uma espécie de **seleção automática de variáveis**.

3.3 Elastic Net

O Elastic Net combina as penalizações L1 e L2. Isso permite equilibrar entre o **encolhimento dos coeficientes** (Ridge) e a **seleção de variáveis** (Lasso). É uma abordagem mais flexível que funciona bem em cenários complexos.

4. Comparação de Modelos

Na prática, vamos comparar o desempenho dos seguintes modelos:

- Regressão Linear Simples
- Regressão Linear Múltipla
- Polynomial Features
- Ridge Regression
- Lasso Regression
- Elastic Net

A comparação será feita em validação simples (train/val/test split) usando métricas como R^2 , MAE e RMSE. O melhor modelo não é o mais complexo, mas sim o que apresenta melhor generalização.