





Regressão Logística: Do Intuitivo ao Prático


Como transformamos combinações lineares em probabilidades
e por que a acurácia raramente conta a história inteira.

O Problema: Regressão Linear



A reta gera valores menores que 0 e maiores que 1. Não faz sentido matemático para probabilidades.

A Solução: Regressão Logística




A função sigmóide esmaga qualquer valor contínuo para dentro de uma probabilidade restrita entre 0 (impossível) e 1 (certeza).

A Máquina de Predição

Etapa 1

A Combinação Linear (z)




Variáveis recebem pesos (coeficientes) gerando um score bruto infinito.

$$z = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$$

Etapa 2

O Filtro Sigmóide (σ)



O score passa pela sigmóide, sendo mapeado para uma escala estrita de 0 a 1.

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Etapa 3

A Decisão (P)



Se $P \geq 0.5$, a classe prevista é 1. Caso contrário, 0.

Fronteiras de Decisão



Em um modelo com duas variáveis (2D), a fronteira de decisão gerada por um modelo linear é sempre uma reta perfeita dividindo o território.

Dissecando a Matriz de Confusão

Realidade da Observação

Era Classe 1
(Positivo)

Era Classe 0
(Negativo)

VP (Verdadeiro
Positivo)

0 modelo disse 1.
0 acerto desejado.

FN (Falso
Negativo)

0 modelo disse 0.
0 erro por omissão fatal.

FP (Falso
Positivo)

0 modelo disse 1.
0 erro por alarme falso.

VN (Verdadeiro
Negativo)

0 modelo disse 0.
A rejeição correta.

A Visão Clássica (Tabela).

True label \ Predicted label	0	1
0	44	1
1	3	42

A Lente Certa: Qual erro dói mais?

Quando o Falso Positivo é Intolerável

Precisão

$$\frac{VP}{VP + FP}$$

Das vezes que gritamos “Lobo!”,
quantas havia um lobo real?

Custo do Erro: Bloquear um e-mail legítimo marcando-o como Spam.

Quando o Falso Negativo é Intolerável

Recall

$$\frac{VP}{VP + FN}$$

De todos os lobos que existiam,
quantos nós detectamos?



Custo do Erro: Deixar um paciente doente ir para casa dizendo que ele está saudável.

O Painel de Equilíbrio: F1-Score

Quando precisamos de equilíbrio absoluto entre Precisão e Recall (especialmente útil em dados desbalanceados), usamos a média harmônica.

$$F1 = 2 \times \frac{(Prec \times Rec)}{(Prec + Rec)}$$

O Trade-off Global



Curva ROC & AUC


Plota a Taxa de Acerto vs o Alarme Falso em todos os limiares possíveis. AUC = 0.5 é cara-e-coroa aleatório. 1.0 é a onisciência perfeita.

Curva Precisão-Recall (PR)

Quando os dados estão desbalanceados (uma classe domina a outra), a curva PR foca apenas no **desempenho da classe minoritária**, sendo a lente da verdade.

O Desafio Titanic


1912. O navio inafundável afunda. A matemática consegue prever quem vive e quem morre com base nos registros dos bilhetes?



Aviso Analítico: Este desbalanceamento nativo exigirá cuidado na avaliação. Um modelo que prevê cegamente a morte para todos já nasceria com 62% de acurácia.

Anatomia de um Naufrágio

O Peso do Gênero




Mulheres tiveram uma taxa de sobrevivência massivamente superior a homens ("Mulheres e crianças primeiro").

O Custo do Bilhete




A Primeira Classe sobrevive a taxas de quase 60%. A geografia vertical do navio selou destinos.

A Faixa Etária




Picos de sobrevivência em idades muito jovens (0-5 anos), contrastando com a alta mortalidade de jovens adultos (20-30 anos).

Os Bastidores: O Pipeline de Dados



O Veredito do Modelo



Acurácia Global: 78.5%

Classe 0 (Morte)

F1-Score: 0.827 | Recall: 83.9%


O modelo domina a identificação da maioria.

Classe 1 (Vida)

F1-Score: 0.714 | Recall: 69.8%

O calcanhar de Aquiles. Mais de 30% dos sobreviventes reais foram tragicamente marcados como mortos, evidência clara do impacto do desbalanceamento.

Abrindo a Caixa Preta: O Cabo de Guerra



Insight Central: Cada coeficiente revela a magnitude e a direção do impacto social de 1912 codificado de forma audível e transparente na matemática.

1

O Domínio das Probabilidades

A natureza binária exige ferramentas construídas para limites. A função sigmóide garante fronteiras lógicas onde a regressão linear produz absurdos.

2

A Falsa Segurança da Acurácia

Em dados desbalanceados, prever apenas o provável cria ilusões. O custo real do modelo reside na interseção de Precisão e Recall. Escute os Falsos Negativos.

3

A Transparência como Poder

Modelos de caixa preta podem prever bem, mas a Regressão Logística nos deixa auditar o porquê. Seus coeficientes revelam a verdadeira história codificada nos dados.