

Aula 7

Regressão Logística

Adaptado dos slides do Prof Samuel Botter

Aula baseada no curso Machine Learning do Prof. Andrew Ng (Coursera)

Exemplos e design inspirados por <https://classeval.wordpress.com/>

Classificação Binária

Tem como saída classes
com apenas 2 valores possíveis

$$y \in \{0, 1\}$$

0 : *Classe Negativa*

1 : *Classe Positiva*

Vestibular: Aprovado / Reprovado

E-mail: Spam / Não-spam

Tumor: Maligno / Benigno

Assinatura: Real / Falsa

Tipo de app: Gratuito / Pago


Classificação Binária

- O dataset usado para treinamento e avaliação de um modelo de um classificador binário contém a classe correta para cada registro de uma observação (amostra).
- Estes registros serão usados para o ajuste do modelo e para comparação com os valores preditos (a classificação realizada) pelo modelo.



Classificação Binária

Se o classificador for perfeito, todas as classificações (previsões da classe) indicarão a mesma classe assinalada nas observações constantes do dataset. Não é de se esperar que isto ocorra. Em geral, apenas parte das previsões coincidem com as observações.




Um modelo de classificador binário

Usaremos de novo um modelo de regressão.

Desta vez, para ***classificarmos*** padrões.

Para tal, o modelo não será linear, precisaremos de algumas alterações, como mostrado a seguir.

Regressão Linear Simples



$$h_{\theta}(x) = \hat{y} = \theta_0 + \theta_1 \cdot x_1 + \dots + \theta_n \cdot x_n$$

$$h_{\theta}(x) = \hat{y} = \theta^T \cdot x$$

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \dots \\ \theta_n \end{bmatrix}$$


$$x = \begin{bmatrix} x_0 \\ x_1 \\ \dots \\ x_n \end{bmatrix}$$

An upward arrow points to the first element of the vector x, which is circled and labeled '1'.

$$\theta^T = [\theta_0 \quad \theta_1 \quad \dots \quad \theta_n]$$

Os **vetores** são comumente representados como **vetores coluna**

Problemas de Classificação




Aplicar uma **Regressão Linear**
em problemas de **classificação**
não parece ser uma boa ideia!

Se $h_{\theta}(x) \geq 0,5 \rightarrow$ classifique $\hat{y} = 1$

Se $h_{\theta}(x) < 0 \rightarrow$ classifique $\hat{y} = 0$

Regressão Logística



Classificação

$$\hat{y} = \begin{cases} 1 & \text{se } \hat{p} \geq 0,5 \\ 0 & \text{se } \hat{p} < 0,5 \end{cases}$$

Modelo de Regressão Logística

$$\hat{p} = h_{\theta}(x) = \frac{1}{1 + e^{-(\theta^T \cdot x)}}$$

$h_{\theta}(x)$ = Probabilidade estimada que a observação representada pelo vetor x , com os parâmetros θ , seja da classe positiva ($y = 1$)

$$h_{\theta}(x) = P(y = 1 | x; \theta)$$

Por exemplo: se

$$x = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ \text{tamanho do tumor} \end{bmatrix} \quad h_{\theta}(x) = 0,7$$

A chance do tumor ser maligno é de **70%**


Regressão Linear X Logística

Modelo de Regressão Logística

$$\hat{p} = h_{\theta}(x) = \sigma(f_{\theta}(x)) = \sigma(\theta^T \cdot x) = \frac{1}{1 + e^{-(\theta^T \cdot x)}}$$


Modelo Linear

$$t = f_{\theta}(x) = \theta^T \cdot x$$




Função Logística (Sigmoide)


$$\hat{p} = \sigma(t) = \frac{1}{1 + e^{-t}}$$




Regressão Logística




Função Logística (Sigmoide)



Modelo de Regressão Logística



Função Logística (Sigmoid)



$\sigma(t)$ retorna um número entre 0 e 1
 $\sigma(t) < 0,5$ quando $t < 0$
 $\sigma(t) \geq 0,5$ quando $t \geq 0$

O modelo de Regressão Logística prediz:

- . classe 1 (positiva) se $(\theta^T \cdot x) \geq 0$
- . classe 0 (negativa) se $(\theta^T \cdot x) < 0$

Treinamento e Função de Custo

Achar o vetor de parâmetros θ de maneira que o modelo estime:

- . probabilidades altas para **instâncias positivas** ($y = 1$)
- . probabilidades baixas para **instâncias negativas** ($y = 0$)

Este vetor será escolhido como aquele que minimiza uma função de custo. Esta função é a



Entropia Cruzada Binária:

$$H_i = -(y_i \cdot \ln(h_\theta(x)) + (1 - y_i) \cdot \ln(1 - h_\theta(x))) \quad \text{ou seja:}$$


$$\theta^T = [\theta_0 \quad \theta_1 \quad \dots \quad \theta_n]$$

Função de Custo

$$H(\theta) = \begin{cases} -\ln(h_\theta(x)) & \text{se } y = 1 \\ -\ln(1 - h_\theta(x)) & \text{se } y = 0 \end{cases}$$



Fronteira de Decisão



Suponha que o melhor vetor θ encontrado foi

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \end{bmatrix} = \begin{bmatrix} -4 \\ 1 \end{bmatrix} \quad x = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ x_1 \end{bmatrix}$$

$\sigma(t)$ retorna um número entre 0 e 1

$\sigma(t) < 0,5$ quando $t < 0$ (classe negativa)

$\sigma(t) > 0,5$ quando $t > 0$ (classe positiva)

$\sigma(t) = 0,5$ quando $t = 0$



Logo o hiperplano $(\theta^T \cdot x) = 0$
forma a **fronteira de decisão** do classificador


$$\theta^T \cdot x = 0$$

$$-4 + 1 \cdot x_1 = 0$$

$$\boxed{x_1 = 4}$$

fronteira de decisão

Fronteira de Decisão : outro exemplo



$$h_{\theta}(x) = \sigma(\theta^T \cdot x) = \sigma(\theta_0 + \theta_1 \cdot x_1 + \theta_2 \cdot x_2)$$

Suponha que o melhor vetor θ encontrado foi

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{bmatrix} = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix} \quad x = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} -3 \\ x_1 \\ x_2 \end{bmatrix}$$

O hiperplano $(\theta^T \cdot x) = 0$
forma a **fronteira de decisão** do classificador

$$\begin{aligned} \theta^T \cdot x &= 0 \\ -3 + 1 \cdot x_1 + 1 \cdot x_2 &= 0 \end{aligned}$$

$$x_1 + x_2 = 3$$

fronteira de decisão

Vantagens da Regressão Logística

- Os resultados são mostrados em formato de probabilidade
- É bastante fácil classificar indivíduos em categorias
- Precisa apenas de um pequeno número de suposições para realizar as previsões
- Possui um alto grau de confiabilidade dos resultados

Avaliação do modelo: Matriz de Confusão

É uma medida de desempenho para **problemas de classificação** em aprendizado de máquina em que a saída consiste em duas ou mais classes. É uma tabela com as quatro combinações dos valores preditos e reais.


Permite o cálculo de métricas importantes: Acurácia/Taxa de erros, Sensibilidade(*Recall*), Precisão, Especificidade, *F-score*, MCC – e a curva AUC-ROV

Significado das células

		PREVISÕES	
		POSITIVOS Previsto como sendo da classe (prevê 1)	NEGATIVOS Previsto como não sendo da classe (prevê 0)
OBSERVAÇÕES	POSITIVOS É da classe (é 1)	TP Verdadeiros Positivos	FN Falsos Negativos
	NEGATIVOS Não é da classe (é 0)	FP Falsos Positivos	TN Verdadeiros Negativos

Saídas possíveis


TP	Verdadeiro Positivo	: Predissemos que era da classe 1 e era mesmo
TN	Verdadeiro Negativo	: Predissemos que era da classe 0 e era mesmo
FP	Falso Positivo	: Predissemos que era da classe 1 e NÃO era (erro do tipo 1)
FN	Falso Negativo	: Predissemos que era da classe 0 e NÃO era (erro do tipo 2)



Taxa de erro

É o que o nome diz: a porcentagem de predições erradas (falsas). Melhor: 0.0, pior 1.0


$$\textit{Taxa de erro} = \frac{FP + FN}{TP + FN + FP + TN} = \frac{FP + FN}{P + N}$$



Acurácia

Indica quanto, de todos os dados de uma amostra, quantos foram previstos corretamente. É **(1 - Taxa de Erro)**. Logo, melhor é 1.0, pior 0.0.



$$\text{Acurácia} = \frac{\text{Total de Acertos}}{\text{Total de itens}} = \frac{TP + TN}{TP + FN + TN + FP} = \frac{TP + TN}{P + N}$$



Sensibilidade (Recall)

Indica quanto, de todas as previsões positivas, quantas foram previstas corretamente
Expressa a ideia de quão bem o modelo aponta a observação como sendo da classe, ou seja, se ele é sensível à classe alvo. Melhor, 1.0, pior 0.0.

$$\textit{Sensibilidade} = \frac{TP}{TP + FN} = \frac{TP}{P}$$




Precisão (Valor preditivo positivo)

Indica quanto, das previsões corretas, quantas eram positivas.

Notem que é um pouco diferente da anterior: expressa a taxa de acerto do modelo para as previsões positivas. Melhor é 1.0, pior é 0.0

$$\text{Precisão} = \frac{TP}{TP + FP}$$



Sensibilidade: quando diz que é da classe, quantas destas previsões o modelo acerta?

Precisão: quando acerta uma previsão, quantos destes acertos é de previsão positiva?


Especificidade (taxa de verdadeiros negativos)

Avalia a capacidade do modelo de detectar resultados negativos.

Expressa o quanto o modelo é adequado a descartar uma observação como sendo da classe alvo.

Melhor 1.0, pior 0.0.

$$\text{Especificidade} = \frac{TN}{TN + FP} = \frac{TN}{N}$$



F-score

Usado para compararmos modelos diferentes. É a média harmônica entre a sensibilidade (recall) e a precisão. Como não usa a média aritmética, penaliza mais os valores extremos

$$F_{\beta} = \frac{(1 + \beta^2)(\text{Precisão} \cdot \text{Sensibilidade})}{(\beta^2 \cdot \text{Precisão} + \text{Sensibilidade})}$$

$$F_1 = \frac{2 \cdot \text{Precisão} \cdot \text{Sensibilidade}}{\text{Precisão} + \text{Sensibilidade}}$$

Em geral, β é 0.5, 1.0 ou 2.0.


Coeficiente de Correlação de Matthews (MCC)

Como o nome indica, expressa o grau de correlação entre observações e previsões, logo é tanto melhor quanto se aproximar de 1.0. Usa todos os valores da matriz de confusão.

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

Métricas

Curva ROC



Curva ROC

- “Receiver Operating Characteristic”
- Usada para avaliar um classificador binário
- Sensibilidade X Especificidade
- Na prática, quanto mais próximo do topo do eixo Y, melhor o classificador

Curva ROC

- Está associada ao conceito de AUC (Area Under the Curve) – a área sob a curva.
- O valor desta área indica a probabilidade de duas previsões serem corretamente feitas.
- AUC será sempre um valor entre 0 e 1.
- Quanto maior este valor, melhor a capacidade do modelo de separar classes