

INTRODUÇÃO AO APRENDIZADO DE MÁQUINA

Validação Cruzada

Como avaliar modelos de forma mais confiável.



HOJE, EM TRÊS PARTES

Três perguntas para avaliar melhor.

-
- | | | |
|----|---------------------------------|---------|
| 01 | Por que treino/teste não basta? | ~10 min |
| 02 | Como funciona o K-Fold? | ~10 min |
| 03 | Como comparar modelos com CV? | ~10 min |
-

01 PARTE UM

Por que treino/teste não basta?


*A avaliação de um modelo depende dos dados que usamos para testar.
Uma única divisão pode enganar.*

Holdout · Generalização · Vazamento


O PROBLEMA DA DIVISÃO ÚNICA

Uma única separação pode mudar a conclusão.


Divisão A



Divisão B



Divisão C



IDEIA

A métrica oscila

O desempenho medido pode variar apenas porque os pontos de teste mudaram.

DOIS ERROS COMUNS

Avaliar mal leva a confiança falsa.

01

Overfitting

O modelo aprende detalhes do treino e parece ótimo nos dados conhecidos, mas falha em dados novos.

02

Data leakage

Informação do teste escapa para o treino. A métrica fica artificialmente otimista.

03

Generalização

O objetivo não é decorar a base. É estimar desempenho em observações futuras.

02 PARTE DOIS


Como funciona o K-Fold Cross Validation?

Dividimos os dados em partes, treinamos várias vezes e deixamos cada parte ser teste uma vez.

Folds · Iterações · Erro médio

A IDEIA CENTRAL

Cada parte dos dados vira teste uma vez.



K-FOLD

Repetição controlada

Treinamos K vezes. Em cada rodada, um fold diferente é usado como teste.


EXEMPLO COM 3 FOLDS

Três iterações, três conjuntos de teste.

01

Iteração 1

Testa no Fold 1



02

Iteração 2

Testa no Fold 2



03

Iteração 3

Testa no Fold 3



DEPOIS DAS ITERAÇÕES

A média dos erros vira uma estimativa mais estável.

FOLD 1

Erro = 0,18

Primeira rodada.

FOLD 2

Erro = 0,22

Segunda rodada.

FOLD 3

Erro = 0,20

Terceira rodada.

MÉDIA = 0,20

Essa média representa melhor o desempenho esperado do que uma única divisão.

03 PARTE TRÊS

Como comparar modelos com CV?

A validação cruzada é especialmente útil quando queremos escolher entre algoritmos ou configurações.

Modelos · Métricas · Scikit-Learn

NA PRÁTICA

A escolha do tipo de CV depende do problema.

01

10-Fold

Muito usado quando há dados suficientes. Equilibra custo computacional e estabilidade.

02

StratifiedKFold

Em classificação, preserva a proporção das classes em cada fold.


03

GroupKFold

Evita que amostras relacionadas apareçam ao mesmo tempo em treino e teste.

CASO EXTREMO

Leave-One-Out testa uma observação por vez.



... repete até todos serem teste uma vez

QUANDO USAR? Bases muito pequenas. Pode ser caro e sensível a ruído.

ESCOLHA DE MODELOS

Comparamos médias, não uma única rodada.

Regressão Logística

0,78 ± 0,04

Árvore de Decisão

0,73 ± 0,08

Random Forest

0,82 ± 0,03

Média ± variação entre folds

DO CONCEITO AO CÓDIGO

No Scikit-Learn, a ideia vira poucas linhas.

```
from sklearn.model_selection import cross_val_score

scores = cross_val_score(modelo, X, y, cv=5, scoring='accuracy')
scores.mean(), scores.std()
```

O mais importante não é decorar a função. É entender o que ela está repetindo por baixo.

TRÊS IDEIAS PARA LEVAR

Se gravar isto, a aula cumpriu sua parte.

01 · POR QUÊ

Uma divisão é frágil

O resultado pode depender da sorte do treino/teste.

02 · COMO

Cada fold testa uma vez

Treinamos várias vezes e calculamos a média.

03 · PARA QUÊ

Comparar melhor

CV ajuda a escolher modelos e hiperparâmetros com menos viés.

AULA PRÁTICA

Vamos abrir o notebook.

A

Usar `cross_val_score`

Comparar métricas médias entre modelos.

B

Testar `KFold` e `StratifiedKFold`

Observar diferenças em bases balanceadas e desbalanceadas.

C

Comparar modelos

Regressão logística, árvore de decisão e random forest.

PERGUNTAS, DÚVIDAS, CONTESTAÇÕES

Obrigado. Vamos conversar?

A avaliação do modelo é parte do modelo. Sem avaliação confiável, a previsão não vale muito.