



PLANO DE AULAS

1 - IDENTIFICAÇÃO		
Curso: CMP.TCN.ADS.2013 - TECNOLOGIA EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS	Período/Ano Letivo 2026/1	
Diário/Componente Curricular: 393816 - SUP.16862 (CMPINAM) - INTRODUÇÃO AO APRENDIZADO DE MÁQUINA - Graduação [66.70 h/80 Aulas]	Código da Disciplina: SUP.16862 (CMPINAM)	
Carga Horária Total: 66,70h/80 Aulas	Carga Horária Semanal: 3,33h/4 Aulas	
Professores: Everton Josue Meyer da Silva (1864472)		

2 - INSTRUMENTOS E CRITÉRIOS DE AVALIAÇÃO DA APRENDIZAGEM
Critério de Avaliação: - Nota primeiro bimestre: $NBIM1 = (0.1 * AP) + (0.05 * PE) + (0.3 * PR)$ - Nota segundo bimestre: $NBIM2 = (0.1 * AP) + (0.05 * PE) + (0.3 * PR)$ - Nota Parcial: $NP = 0.45 * NBIM1 * NBIM2 + 0.1 * SimEnade$ - Nota Final: $NF = \text{máximo} \{IFA, NP\}$ ----- Onde: - AP : Atividades Práticas (20%) - PE: Participação e Engajamento (10%) - PR: Projeto da Disciplina (60%) - SimEnade: Nota do simulado enade (10%) - IFA: Instrumento Final de Avaliação

3 - DESENVOLVIMENTO DAS AULAS		
SEMANA DATA	CONTEÚDO	METODOLOGIAS DE ENSINO E RECURSOS
1 6 de Agosto de 2025	Apresentação do curso e Introdução ao Aprendizado de Máquina Apresentação da disciplina, objetivos, ementa e expectativas. O que é Aprendizado de Máquina (AM), principais áreas e aplicações. Visão geral do pipeline (dados → preparação → modelagem → avaliação).	Metodologia: Aulas expositivas/práticas com exemplos reais e debate curto; Recursos: Slides de apresentação, vídeos curtos.
2 13 de Agosto de 2025	Ambiente de Desenvolvimento em Python e Tutorial de Linguagem Instalação e configuração do ambiente em Python. Introdução ao Jupyter Notebook/Colab. Revisão de Python aplicada a dados (estruturas, funções, Pandas básico, gráficos com Matplotlib/Seaborn).	Metodologia: Aulas 1–2 expositivas/práticas com live coding; Aulas 3–4 prática guiada (scripts simples e manipulação de dados). Recursos: Tutoriais em PDF, Jupyter/Colab, notebooks de exercícios introdutórios.
3 20 de Agosto de 2025	Coleta, organização e EDA (Exploratory Data Analysis) Carregar e inspecionar dados; tipos de variáveis; estatística descritiva essencial; visualizações úteis (distribuições, dispersões, boxplots). Checklist de qualidade de dados.	Metodologia: Aulas 1–2 expositivas/práticas (exemplos dirigidos); Aulas 3–4 prática guiada (EDA em duplas). Recursos: Jupyter Notebooks, Pandas, Matplotlib/Seaborn, datasets simples (ex.: Iris/California Housing).
4 23 de Agosto de 2025	Preparação de dados e divisão treino/teste Divisão treino/teste e validação simples, evitando data leakage. Limpeza de nulos, encoding	Metodologia: Aulas 1–2 expositivas/práticas (live coding dos passos); Aulas 3–4 prática guiada com checklist.

	categorico e feature scaling. Uso de Pipeline no scikit-learn.	Recursos: Jupyter Notebooks, scikit-learn, datasets de prática.
5 27 de Agosto de 2025	Paradigmas e tarefas na prática Supervisionado vs. não supervisionado vs. reforço. Tarefas típicas (regressão, classificação, agrupamento). Montagem de um baseline simples (regressão e classificação).	Metodologia: Aulas 1–2 expositivas/práticas com exemplos; Aulas 3–4 prática guiada (baseline por grupo). Recursos: Slides, notebooks com esqueleto, datasets curtos.
6 3 de Setembro de 2025	Modelos de Regressão I (Regressão Linear) Intuição de regressão; métricas MAE/MSE/RMSE. Underfitting/overfitting e curvas de aprendizado.	Metodologia: Aulas 1–2 expositivas/práticas (ajuste e avaliação); Aulas 3–4 prática guiada em exercícios. Recursos: Jupyter Notebooks, scikit-learn, conjuntos de dados tabulares.
7 10 de Setembro de 2025	Modelos de Regressão II (Melhorias e Regularização) Polynomial features, regularização (Ridge, Lasso, Elastic Net). Comparação de modelos em validação simples.	Metodologia: Aulas 1–2 expositivas/práticas; Aulas 3–4 prática guiada com estudo de caso. Recursos: Notebooks com TODOS, scikit-learn.
8 17 de Setembro de 2025	Algoritmos de Classificação I (Regressão Logística e Métricas) Classificação binária com Regressão Logística. Matriz de confusão, precisão, recall, F1; ajuste de limiar e leitura das curvas ROC/PR.	Metodologia: Aulas 1–2 expositivas/práticas com live coding; Aulas 3–4 prática guiada com exercícios. Recursos: Notebooks, datasets de classificação (ex.: dígitos, churn, crédito).
9 24 de Setembro de 2025	Algoritmos de Classificação II (Árvores e k-NN) Árvores de decisão (intuição, importância de atributos) e k-NN (vizinhos mais próximos). Quando escolher cada um. Cuidados com desbalanceamento.	Metodologia: Aulas 1–2 expositivas/práticas; Aulas 3–4 prática guiada. Recursos: Jupyter Notebooks, scikit-learn.
10 1 de Outubro de 2025	Entrega do Projeto (Marco 1) Entrega do MVP do projeto: problema definido, EDA, preparação dos dados, baseline (regressão e/ou classificação) com métrica e próximos passos.	Metodologia: Aulas 1–2 mentoria/checklist por grupo; Aulas 3–4 entrega formal e registro de lições aprendidas. Recursos: Rubrica de avaliação, template de entrega, formulário de feedback.
11 8 de Outubro de 2025	Validação de Modelos e Ajuste de Hiperparâmetros K-fold cross-validation (intuição), hold-out final. GridSearchCV e RandomizedSearchCV (como pensar hiperparâmetros, sem fórmulas).	Metodologia: Aulas 1–2 expositivas/práticas; Aulas 3–4 prática guiada (experimentos por grupo). Recursos: Notebooks, scikit-learn.
12 22 de Outubro de 2025	Métricas na Prática e Comparação Justa Métricas de regressão (MAE, MSE/RMSE, R^2) e classificação (F1, ROC/PR). Como comparar modelos de forma justa e evitar leakage.	Metodologia: Aulas 1–2 expositivas/práticas; Aulas 3–4 prática guiada com avaliação de modelos. Recursos: Notebooks de avaliação, datasets de validação.
13 25 de Outubro de 2025	Desbalanceamento de Classes Como o desbalanceamento afeta as métricas. Estratégias: class_weight, undersampling, oversampling/SMOTE (intuição). Ajuste de limiar orientado a custo.	Metodologia: Aulas 1–2 expositivas/práticas; Aulas 3–4 prática guiada com experimentos. Recursos: Notebooks, scikit-learn, imbalanced-learn (se disponível).
14 29 de Outubro de 2025	Algoritmos de Agrupamento K-means e DBSCAN. Avaliação com silhueta. Casos de uso comuns.	Metodologia: Aulas 1–2 expositivas/práticas; Aulas 3–4 prática guiada com clusters. Recursos: Notebooks, scikit-learn.

15 5 de Novembro de 2025	Redução de Dimensionalidade e Visualização PCA e noções de t-SNE/UMAP para visualização. Uso prévio a clusterização ou classificação.	Metodologia: Aulas 1–2 expositivas/práticas; Aulas 3–4 prática guiada. Recursos: Notebooks, scikit-learn.
16 12 de Novembro de 2025	Ensemble Learning Bagging vs. Boosting. Random Forest e visão de Gradient Boosting. Vantagens e cuidados (overfitting, tempo).	Metodologia: Aulas 1–2 expositivas/práticas; Aulas 3–4 prática guiada com comparações. Recursos: Notebooks, scikit-learn.
17 19 de Novembro de 2025	Projeto: refinamento e narrativa do resultado Diagnóstico de erros, melhorias finais, documentação. Estrutura do slide/relatório (problema → dados → métrica → resultado → limitações).	Metodologia: Aulas 1–2 mentoria técnica; Aulas 3–4 prática focada no projeto (revisões em grupo).
18 26 de Novembro de 2025	Apresentação de Projetos (Seminários) — Parte 1 Apresentação dos projetos finais pelos alunos (1ª metade da turma).	Metodologia: Seminários com apresentações de grupos e feedback estruturado. Recursos: Laboratório e projetor.
19 3 de Dezembro de 2025	Apresentação de Projetos (Seminários) — Parte 2 Continuação das apresentações dos projetos finais (2ª metade da turma).	Metodologia: Seminários com apresentações de grupos e feedback estruturado. Recursos: Laboratório e projetor.
20 10 de Dezembro de 2025	Encerramento do Semestre Encerramento da disciplina, revisão dos conteúdos e fechamento de notas.	Metodologia: Aula expositiva e discussão final. Recursos: Feedback dos alunos, revisão de provas e trabalhos.

Assinaturas			
PROFESSOR		COORDENADOR DO CURSO	
DATA	DATA		
___/___/___	___/___/___		

